

# Прогнозирование виральности постов в социальных сетях

Выполнили:  
Офицеров Дмитрий  
Офицеров Максим



# Работа с датасетом

Датасет на Kaggle:

<https://www.kaggle.com/datasets/sachinkanchan92/reddit-top-posts-50-subreddit-analysis-2011-2024/data>

Объединенный датасет: всего записей: 49,266

Колонки: [cleaned\_text, score, upvote\_ratio, num\_comments, created\_utc, subreddit, source\_file, title]

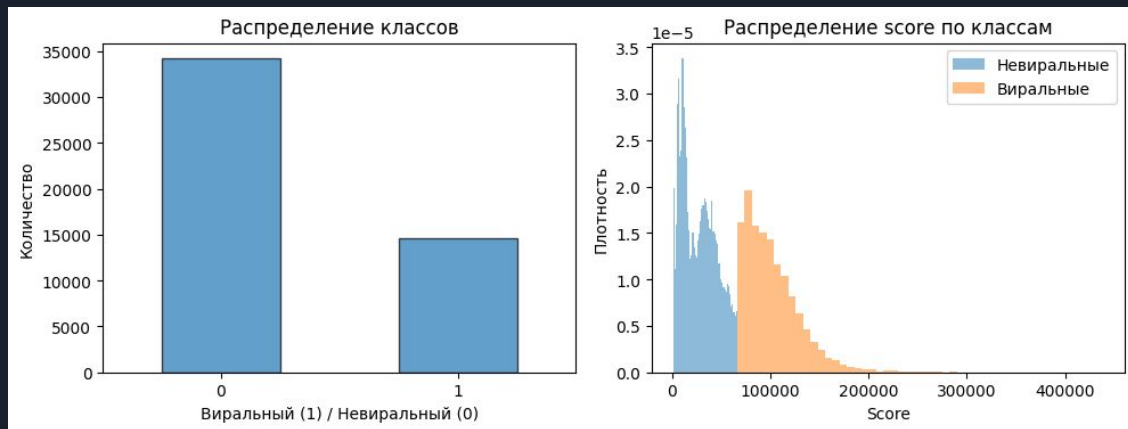
Уникальных субреддитов: 50

Статистика по score: минимум: 1,115, максимум: 438,828, среднее: 50,107, медиана: 39,192

Средняя длина текста: 360 символов, минимальная длина: 1, максимальная длина: 39929

# Сведение задачи к бинарной классификации

Метка виральности: верхние 30% по score

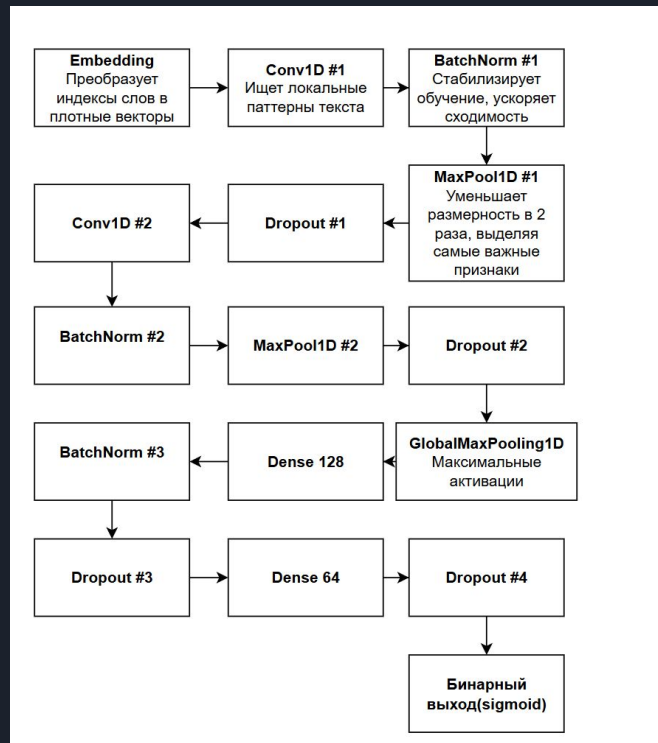


т.к. текст уникальный, применили оверсэмплинг для балансировки классов

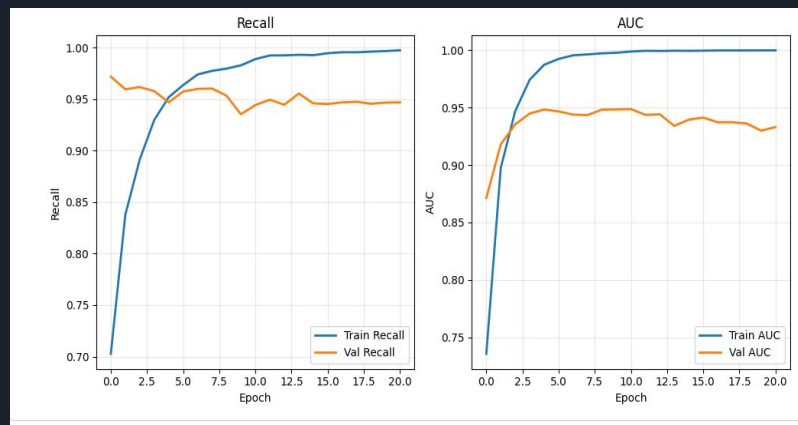
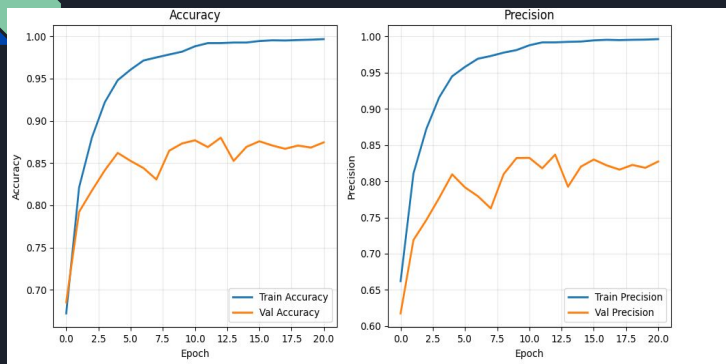
# Архитектура CNN

Ключевые особенности:

1. Улавливает n-граммы (словосочетания) через Conv1D
2. Независимость от длины текста через GlobalPooling
3. Регуляризация (Dropout в каждом блоке)
4. Стабильное обучение, ускоренная сходимость (BatchNorm после каждого Conv1D)
5. Иерархическое извлечение признаков (как в CNN для изображений)



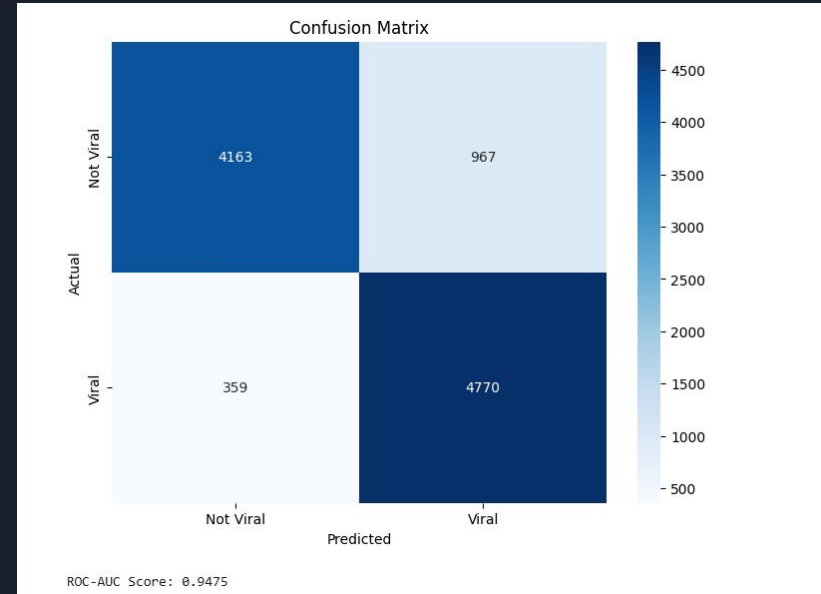
# Обучение



# Промежуточный итог

Итоговые метрики для этого подхода:

	precision	recall	f1-score
Not Viral	0.92	0.81	0.86
Viral	0.83	0.93	0.88
accuracy	0.87		





# Регрессия на трансформере BERT

Модель можно условно разбить на три компонента-обработчика:

1. Текстовый контент (BERT)

Понимание семантики, тональности и информационной ценности текста

2. Числовые данные

Учет признаков: `upvote_ratio` (отношение голосов), `num_comments` (количество комментариев), `text_length` (длина текста)

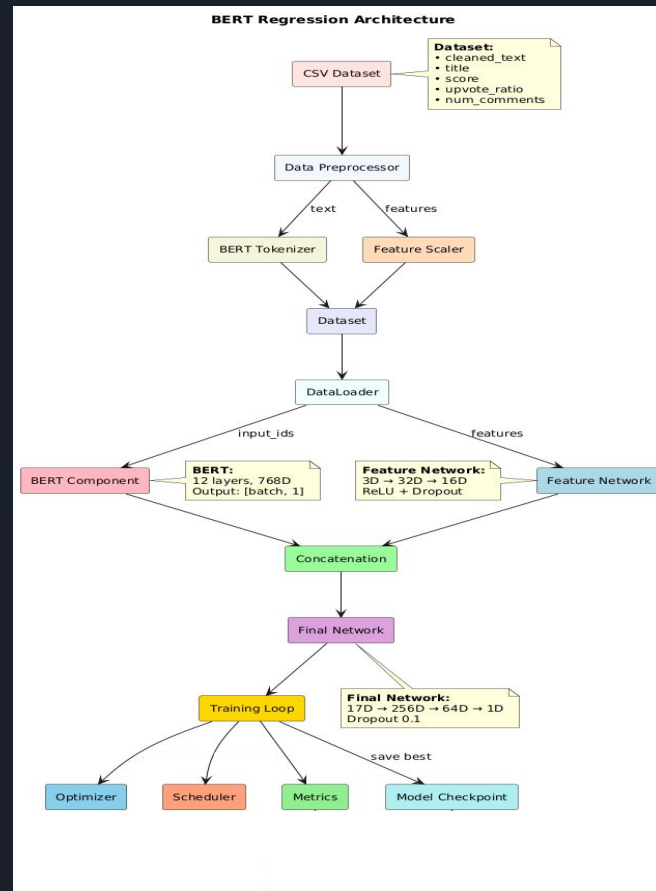
3. Объединённое представление (Финальная нейросеть)

Конкатенация текстовых и числовых признаков

# Архитектура решения

Модель обучалась на видеокарте rtx 2060  
с 6gb видеопамяти с применением pytorch  
+ Cuda Toolkit от Nvidia.

Обучение и валидация заняли ~30 минут.







# Метрики

Тесты на лучшей модели:

Test Results:

Loss: 0.3193

RMSE: 0.5649

MAE: 0.3965

$R^2$  Score: 0.6983

Пример 1:

Предсказанный score: 37018.6

Реальный score: 27922.0

Разница: 9096.6

Пример 2:

Предсказанный score: 101589.8

Реальный score: 78494.0

Разница: 23095.8

Пример 3:

Предсказанный score: 13448.3

Реальный score: 14889.0

Разница: 1440.7



# Выводы

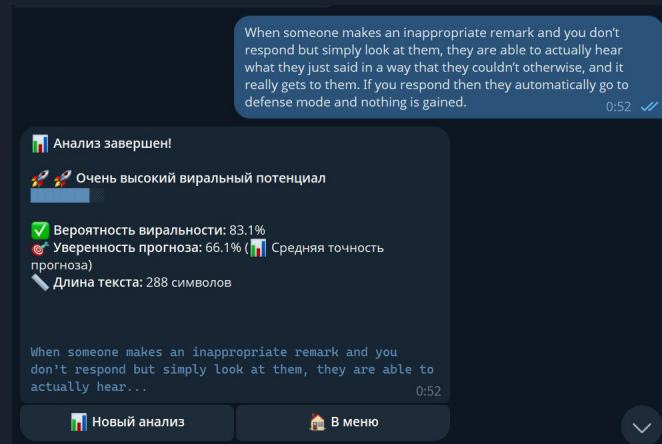
Модель на основе собственной CNN, решавшая задачу бинарной классификации справилась лучше, но с более простой задачей. Трансформер показал более плохие метрики и потребовал гораздо большего времени на разработку и отладку. Несмотря на это, модель на базе BERT имеет широкие возможности для дополнительного анализа и масштабируемости. Стоит отметить и сложность самой задачи построения регрессионной модели на имеющихся данных: зачастую фактическая виральность текста близка к хаотичной, и успешным уже можно считать результат близкого совпадения score.

# Графическая оболочка

В качестве графической оболочки был написан бот в Telegram, с использованием Aiogram 3.11

Бот имеет inline-кнопки для быстрой и удобной навигации и работе с моделью


Пример работы бота на слайде



# Примеры работы

Первый комментарий: 18%  
Второй комментарий: 15%


Первый комментарий: 80%  
Второй комментарий: 12%

 [удалено] • 8 л. назад

Cute story my old chemistry teacher told me. She had a boy who was brilliant but never tried and failed the class as a result. Next year he was back and she seated him next to a pretty, very smart girl. You bet he worked his ass off to impress her. They're now married with two kids.

4,6 тыс. Награда Поделиться ...


Еще 59 ответов

 **Mattyb2851** • 8 л. назад

My mother was an elementary school teacher who assigned a class project to write a letter to people in the military to be delivered randomly. My dad was in the navy and didn't get much mail, so when "extra" randomly assigned mail came in, he would sometimes get it. Turns out, my dad got my mom's letter and decided to write back

1,4 тыс. Награда Поделиться ...


Еще 12 ответов

 **bdbbokbuck** • 4 г. назад

When someone makes an inappropriate remark and you don't respond but simply look at them, they are able to actually hear what they just said in a way that they couldn't otherwise, and it really gets to them. If you respond then they automatically go to defense mode and nothing is gained.

1 тыс. Ответить Награда Поделиться ...

Еще 70 ответов

 **Kortrak** • 4 г. назад

I was in a disco a few years ago and this guy walked up to us and said "you're doing it wrong" out of the blue, no idea what he even was referring to (probably our dancing idk), just looked the other way, shrugged it off and continued, my friend asked me why I did not argue with him.

Later that night the bouncers had to escort him out of the club because he got into a fight with someone and knocked him out.

That's why. There is nothing to gain, only to lose arguing with some people

226 Ответить Награда Поделиться ...

Еще 8 ответов